

# UNIVERSIDAD NACIONAL DE INGENIERIA

---

Facultad de Ingeniería Económica, Estadística y CC.SS.

Curso: Modelos Lineales

## Modelos Lineal General

Eduardo Marcos Sánchez



# Modelos

- Tenemos el modelo con  $K$  variables

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_K X_{Ki} + u_i, \quad i = 1, \dots, n$$

- Y vimos que usando matrices puede escribirse como

$$Y = X\beta + u$$

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{21} & X_{31} & \cdots & X_{K1} \\ 1 & X_{22} & X_{32} & \cdots & X_{K2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{2n} & X_{3n} & \cdots & X_{Kn} \end{bmatrix} \cdot \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

donde  $X$  es  $(n \times K)$ ,  $Y$  y  $u$  son  $(n \times 1)$ , y  $\beta$  es  $(K \times 1)$ .

# Definiciones

---

- Vector de estimadores  $\hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_K \end{bmatrix}$
- Vector de estimaciones de  $Y$  ( $n \times 1$ ):  $\hat{Y} \equiv X\hat{\beta}$
- Vector de residuos o errores de estimación ( $n \times 1$ ):  
 $e \equiv Y - \hat{Y} = Y - X\hat{\beta}$

# Definiciones

- $$X'X = \begin{bmatrix} n & \sum X_{2i} & \sum X_{3i} & \cdots & \sum X_{Ki} \\ \sum X_{2i} & \sum X_{2i}^2 & \sum X_{2i}X_{3i} & \cdots & \sum X_{2i}X_{Ki} \\ \sum X_{3i} & \sum X_{2i}X_{3i} & \sum X_{3i}^2 & \cdots & \sum X_{3i}X_{Ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum X_{Ki} & \sum X_{2i}X_{Ki} & \sum X_{3i}X_{Ki} & \cdots & \sum X_{Ki}^2 \end{bmatrix}$$
- La existencia de  $(X'X)^{-1}$  se garantiza por el supuesto de no multicolinealidad perfecta.
- Recordemos: si no hay multicolinealidad perfecta  $\rho(X) = K$ , lo que a su vez implica que  $\rho(X'X) = K \Rightarrow \exists (X'X)^{-1}$

# Supuestos

---

$$1. E(u) = \begin{bmatrix} E(u_1) \\ E(u_2) \\ \vdots \\ E(u_n) \end{bmatrix} = \mathbf{0}$$

$$2. VarCov(u) = \begin{bmatrix} V[u_1] & Cov[u_1, u_2] & \cdots & Cov[u_1, u_n] \\ Cov[u_2, u_1] & V[u_2] & \cdots & Cov[u_2, u_n] \\ \vdots & \vdots & \ddots & \vdots \\ Cov[u_n, u_1] & Cov[u_n, u_2] & \cdots & V[u_n] \end{bmatrix} = \sigma^2 I_n$$

$$3. X_{n \times K} \text{ no estocástica con } \rho(X) = K$$

# Supuestos

- Insesgadez:  $E[\hat{\beta}] = \beta$
- Matriz de varianzas y covarianzas:  $VarCov(\hat{\beta}) = \sigma^2(X'X)^{-1}$

$$= \begin{bmatrix} V[\hat{\beta}_1] & Cov[\hat{\beta}_1, \hat{\beta}_2] & \cdots & Cov[\hat{\beta}_1, \hat{\beta}_K] \\ Cov[\hat{\beta}_1, \hat{\beta}_2] & V[\hat{\beta}_2] & \cdots & Cov[\hat{\beta}_2, \hat{\beta}_K] \\ \vdots & \vdots & \ddots & \vdots \\ Cov[\hat{\beta}_1, \hat{\beta}_K] & Cov[\hat{\beta}_2, \hat{\beta}_K] & \cdots & V[\hat{\beta}_K] \end{bmatrix}$$
$$= \begin{bmatrix} \sigma^2 A_{11} & \sigma^2 A_{12} & \cdots & \sigma^2 A_{1K} \\ \sigma^2 A_{21} & \sigma^2 A_{22} & \cdots & \sigma^2 A_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^2 A_{K1} & \sigma^2 A_{K2} & \cdots & \sigma^2 A_{KK} \end{bmatrix}$$

donde  $A_{kk}$  es el elemento en la fila  $k$  y columna  $k$  de la matriz  $(X'X)^{-1}$

- El estimador de  $VarCov(\hat{\beta})$  es  $Var\hat{Cov}(\hat{\beta}) = S^2(X'X)^{-1}$   
con  $S^2 = \frac{e'e}{n-K}$

# Supuestos

## Definición: matriz semidefinida positiva

Sea  $H$  una matriz  $m \times m$  y sea  $c$  cualquier vector de  $m$  constantes. Se dice que  $H$  es semidefinida positiva si y sólo si  $c'Hc \geq 0 \forall c \in \mathbb{R}^m$

- Notar:
  - que  $c'Hc$  es  $(1 \times 1)$ , o sea, un número real.
  - $c'Hc$  es una **forma cuadrática**. Para ver por qué, desarrollar la expresión para  $m = 2$ .
- **Importante:** cualquier matriz de varianzas y covarianzas es semidefinida positiva.
  - En particular,  $\text{VarCov}[\hat{\beta}]$  es semidefinida positiva.

# Supuestos

- Entonces, para cualquier vector de constantes  $c$  de dimensión  $K \times 1$  se cumple que  $c' \text{VarCov}[\hat{\beta}]c \geq 0$ .
- La expresión  $c' \text{VarCov}[\hat{\beta}]c$  es la varianza de la combinación lineal  $c'\hat{\beta}$ .
- Veamos el ejemplo para  $K = 2$ :
  - $c'\hat{\beta} = c_1\hat{\beta}_1 + c_2\hat{\beta}_2$
  - $V[c'\hat{\beta}] = c' \text{VarCov}[\hat{\beta}]c = c_1^2 V[\hat{\beta}_1] + c_2^2 V[\hat{\beta}_2] + 2c_1c_2 \text{Cov}[\hat{\beta}_1, \hat{\beta}_2]$
  - La semidefinición positiva garantiza que esta última expresión es  $\geq 0$ .
- Entonces todos los siguientes casos particulares son  $\geq 0$ :
  - Si  $c_1 = 1$  y  $c_2 = 0 \Rightarrow V[c'\hat{\beta}] = V[\hat{\beta}_1] \geq 0$
  - Si  $c_1 = 0$  y  $c_2 = 1 \Rightarrow V[c'\hat{\beta}] = V[\hat{\beta}_2] \geq 0$
  - Si  $c_1 = 1$  y  $c_2 = 1 \Rightarrow V[c'\hat{\beta}] = V[\hat{\beta}_1] + V[\hat{\beta}_2] + 2\text{Cov}[\hat{\beta}_1, \hat{\beta}_2] \geq 0$
  - Si  $c_1 = 1$  y  $c_2 = -1 \Rightarrow V[c'\hat{\beta}] = V[\hat{\beta}_1] + V[\hat{\beta}_2] - 2\text{Cov}[\hat{\beta}_1, \hat{\beta}_2] \geq 0$



# Teorema de Gauss Markov

---

- Bajo todos los supuestos clásicos, el estimador de MCO es el más eficiente de todos los estimadores lineales e insesgados.
- **Mejor Estimador Lineal e Insesgado (MELI).**
- **Además:** sea  $c$  un vector de  $K$  constantes arbitrarias  $c_1, c_2, \dots, c_K$ ,  $c'\hat{\beta}$  es el mejor estimador lineal e insesgado de  $c'\beta$ .
  - Es decir, la combinación lineal de los estimadores MCO es MELI para estimar la combinación lineal de los parámetros.

$$\underline{M \mid C:} \quad \varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}) \quad \left\{ \begin{array}{l} \Rightarrow \underline{\hat{\beta} \sim N_{p+1}(\beta; \sigma^2 (X'X)^{-1})} \end{array} \right.$$

$$\text{si } y = X\beta + \varepsilon$$

$$\text{Dem: } \underline{\hat{\beta} = (X'X)^{-1} X'y}$$

$$\text{como } y = X\beta + \varepsilon \quad y \quad \varepsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

$$\Rightarrow y \sim N_n(X\beta, \sigma^2 \mathbf{I}_n)$$

$y \Rightarrow \hat{\beta}$  es una Norm. Multivari.

$$\Rightarrow \underline{\tilde{\sigma}^2 \sim \frac{\sigma^2}{n-p-1} \chi^2_{(n-p-1)}}$$

$$\text{Dem: } \tilde{\sigma}^2 = \frac{\hat{\varepsilon}' \hat{\varepsilon}}{n-p-1} = \frac{\varepsilon' M_X \varepsilon}{n-p-1} = \varepsilon' A \varepsilon$$

$$\Rightarrow A \Sigma = \frac{M_X \sigma^2}{n-p-1} = \frac{\sigma^2}{n-p-1} M_X$$

$A \Sigma$  es múltiplo de una matriz  $M_X$  idempotente

$$y \quad C = \frac{\sigma^2}{n-p-1}$$

$$\Rightarrow \sigma^2 \sim \frac{\sigma^2}{n-p-1} \sim \chi^2_{(n-p-1)}$$

•)  $\frac{\hat{\varepsilon}'\hat{\varepsilon}}{\sigma^2} \sim \chi^2_{(n-p-1)}$

---

•)  $\hat{\beta}_{MCO}$  y  $\hat{\sigma}^2_{MCO}$  son indep.

---

Dem:  $\hat{\beta}_{MCO} = (X'X)^{-1} X'Y \dots (1)$

$\hat{\sigma}^2_{MCO}: \frac{\hat{\varepsilon}'\hat{\varepsilon}}{n-p-1} = \frac{Y'M_1Y}{n-p-1} = \frac{1}{n-p-1} (M_1Y)'(M_1Y)$

$(Z = M_1Y)$

$\Rightarrow \hat{\sigma}^2_{MCO} = \frac{1}{n-p-1} Z'Z$

$Cov(\hat{\beta}_{MCO}, Z) = Cov((X'X)^{-1}X'Y, M_1Y)$   
 $= (X'X)^{-1}X'(\sigma^2 I_n)M_1 \Rightarrow \sigma^2(X'X)^{-1}X'M_1$

$Z$  y  $\hat{\beta}_{MCO}$  son indep.  $\leftarrow$   
 $\hat{\sigma}^2 = \frac{Z'Z}{n-p-1} = \frac{\hat{\varepsilon}'\hat{\varepsilon}}{n-p-1}$  y  $\hat{\beta}_{MCO}$   
 $= 0$

EMV

\*)

$$\hat{\beta}_{MV} = \hat{\beta}_{MLE}$$

$$Y \sim N(X\beta; \sigma^2 I_n)$$

$$\hat{\sigma}_{MV}^2 = \frac{(Y - X\hat{\beta}_{MV})'(Y - X\hat{\beta}_{MV})}{n}$$

Modelo Reg LINEAL Multiple

$$Z = \begin{bmatrix} y \\ x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix}$$

$$E(Z) = \begin{bmatrix} \mu_y \\ \mu_x \end{bmatrix}$$

$$V(Z) = \begin{bmatrix} \sigma_y^2 & \dots & \sigma_{y0} \\ \vdots & \ddots & \vdots \\ \sigma_{0y} & \dots & \Sigma_x \end{bmatrix}$$

$$Z \sim N_{p+1}(\mu_Z; \Sigma_Z)$$

$$\alpha = (\alpha_1, \alpha_2, \dots, \alpha_p)' = \arg \max_{\alpha \neq 0} f(y; \alpha'x)$$

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \epsilon_i$$

$$y_i = \underbrace{\beta_0 + \beta_1 \bar{x}_1 + \beta_2 \bar{x}_2 + \dots + \beta_p \bar{x}_p}_{\alpha} + \beta_1(x_{i1} - \bar{x}_1) + \beta_2(x_{i2} - \bar{x}_2) + \dots + \beta_p(x_{ip} - \bar{x}_p) + e_i$$

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}}_Y = \underbrace{\begin{pmatrix} 1 & x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \dots & x_{1p} - \bar{x}_p \\ 1 & \vdots & \vdots & \ddots & \vdots \\ 1 & \vdots & \vdots & \ddots & x_{np} - \bar{x}_p \end{pmatrix}}_{X^*} \underbrace{\begin{pmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}}_{\beta^*} + \underbrace{\begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}}_e$$

$$Y = X^* \beta^* + e$$

$$\arg \max_{\beta^*} (Y, X^* \beta^*)$$

$$E(Y|X) = \mu_y + \sigma_{y0} \bar{\Sigma}^{-1} (X - \mu_x) = \underbrace{\mu_y - \sigma_{y0} \bar{\Sigma}^{-1} \mu_x}_{\beta_0} + \underbrace{\sigma_{y0} \bar{\Sigma}^{-1}}_{\alpha'} X = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

- Sea el modelo  $Y=XB+e$  con termino independiente y " $\beta$ " variables explicativa. Si consideramos un conjunto de variables explicativas alternativo  $Z=XP$ , donde  $X$  es la matriz de datos original y  $P$  es no singular. Pruebe que el ajuste del modelo se mantiene. (suger. Considerar  $R^2 = SCReg/SCTotal$ )

Modelo 1:  $y = X\beta + e$

$$SC_{Reg} = Y'(H_X - \frac{1}{n}J_n)Y$$

$$SC_{Total} = Y'(I_n - \frac{1}{n}J_n)Y$$

$$\Rightarrow R^2 = \frac{Y'(H_X - \frac{1}{n}J_n)Y}{Y'(I_n - \frac{1}{n}J_n)Y}$$

Modelo 2:  $y = Z\beta^* + e^*$

$$SC_{Reg} = Y'(H_Z - \frac{1}{n}J_n)Y = Y'(Z(Z'Z)^{-1}Z' - \frac{1}{n}J_n)Y$$

$$SC_{Total} = Y'(H_X - \frac{1}{n}J_n)Y$$

$$R^2 = \frac{Y'(H_Z - \frac{1}{n}J_n)Y}{Y'(I_n - \frac{1}{n}J_n)Y}$$

=  $\rightarrow$  mantienep

- Se tiene un modelo de regresión conformado por  $p$  variables explicativas, luego se decide incorporar una variable independiente adicional. Analizar matemáticamente que efecto ocasiona la inclusión de esta nueva variable en el  $R^2$ .

$$R^2 = 1 - \frac{SCE}{SCT}$$

$$\text{Model 1: } Y = X\beta + \varepsilon \Rightarrow SCE = \hat{\varepsilon}'\hat{\varepsilon}$$

$$\text{Model 2: } Y = \begin{pmatrix} X & Z \end{pmatrix} \begin{pmatrix} \beta \\ \alpha \end{pmatrix} + \varepsilon^*$$

$$\Rightarrow Y = X\beta + \alpha Z + \varepsilon^*$$

$$SCE_n = \hat{\varepsilon}^{*'}\hat{\varepsilon}^* = (Y - X\hat{\beta} - \hat{\alpha}Z)(Y - X\hat{\beta} - \hat{\alpha}Z)'$$

$$= \underbrace{(Y - X\hat{\beta})'(Y - X\hat{\beta})}_{SCE_1} - 2(Y - X\hat{\beta})'\hat{\alpha}Z + \hat{\alpha}'Z'Z\hat{\alpha}$$

$$\hat{\varepsilon}^{*'}\hat{\varepsilon}^* = \hat{\varepsilon}'\hat{\varepsilon} - 2\hat{\alpha}'(Y - X\hat{\beta})Z + \hat{\alpha}'Z'Z\hat{\alpha} \quad (I)$$

$$\text{Para } Z'\hat{\varepsilon}^* = 0 \rightarrow Z'(Y - X\hat{\beta} - \hat{\alpha}Z) = 0$$

$$= Z'(Y - X\hat{\beta}) - \hat{\alpha}'Z'Z$$

$$\Rightarrow (Y - X\hat{\beta})Z' = \hat{\alpha}'Z'Z \quad (II)$$

(II) en (I)

$$\hat{\varepsilon}^{*'}\hat{\varepsilon}^* = \hat{\varepsilon}'\hat{\varepsilon} - 2\hat{\alpha}'Z'Z\hat{\alpha} + \hat{\alpha}'Z'Z\hat{\alpha}$$

$$\Rightarrow \hat{\varepsilon}^{*'}\hat{\varepsilon}^* = \hat{\varepsilon}'\hat{\varepsilon} - \hat{\alpha}'Z'Z\hat{\alpha} \leq 0$$

$$\hat{\varepsilon}^{*'}\hat{\varepsilon}^* \leq \hat{\varepsilon}'\hat{\varepsilon}$$

$$\frac{SCE_{(2)}}{SCE_{(1)}} \leq SCE_{(1)} \Rightarrow R^2_{(2)} \geq R^2_{(1)}$$