

# UNIVERSIDAD NACIONAL DE INGENIERIA

---

Facultad de Ingeniería Económica, Estadística y CC.SS.

Curso: Modelos Lineales

**Modelos Lineal General**

Eduardo Marcos Sánchez



# Modelos

- Tenemos el modelo con  $K$  variables

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_K X_{Ki} + u_i, \quad i = 1, \dots, n$$

- Y vimos que usando matrices puede escribirse como

$$Y = X\beta + u$$

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{21} & X_{31} & \cdots & X_{K1} \\ 1 & X_{22} & X_{32} & \cdots & X_{K2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{2n} & X_{3n} & \cdots & X_{Kn} \end{bmatrix} \cdot \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

donde  $X$  es  $(n \times K)$ ,  $Y$  y  $u$  son  $(n \times 1)$ , y  $\beta$  es  $(K \times 1)$ .

# Definiciones

---

- Vector de estimadores  $\hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_K \end{bmatrix}$
- Vector de estimaciones de  $Y$  ( $n \times 1$ ):  $\hat{Y} \equiv X\hat{\beta}$
- Vector de residuos o errores de estimación ( $n \times 1$ ):  
 $e \equiv Y - \hat{Y} = Y - X\hat{\beta}$

# Definiciones

- $$X'X = \begin{bmatrix} n & \sum X_{2i} & \sum X_{3i} & \cdots & \sum X_{Ki} \\ \sum X_{2i} & \sum X_{2i}^2 & \sum X_{2i}X_{3i} & \cdots & \sum X_{2i}X_{Ki} \\ \sum X_{3i} & \sum X_{2i}X_{3i} & \sum X_{3i}^2 & \cdots & \sum X_{3i}X_{Ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum X_{Ki} & \sum X_{2i}X_{Ki} & \sum X_{3i}X_{Ki} & \cdots & \sum X_{Ki}^2 \end{bmatrix}$$
- La existencia de  $(X'X)^{-1}$  se garantiza por el supuesto de no multicolinealidad perfecta.
- Recordemos: si no hay multicolinealidad perfecta  $\rho(X) = K$ , lo que a su vez implica que  $\rho(X'X) = K \Rightarrow \exists (X'X)^{-1}$

# Supuestos

---

$$1. E(u) = \begin{bmatrix} E(u_1) \\ E(u_2) \\ \vdots \\ E(u_n) \end{bmatrix} = \mathbf{0}$$

$$2. VarCov(u) = \begin{bmatrix} V[u_1] & Cov[u_1, u_2] & \cdots & Cov[u_1, u_n] \\ Cov[u_2, u_1] & V[u_2] & \cdots & Cov[u_2, u_n] \\ \vdots & \vdots & \ddots & \vdots \\ Cov[u_n, u_1] & Cov[u_n, u_2] & \cdots & V[u_n] \end{bmatrix} = \sigma^2 I_n$$

$$3. X_{n \times K} \text{ no estocástica con } \rho(X) = K$$

# Supuestos

- Insesgadez:  $E[\hat{\beta}] = \beta$
- Matriz de varianzas y covarianzas:  $VarCov(\hat{\beta}) = \sigma^2(X'X)^{-1}$

$$= \begin{bmatrix} V[\hat{\beta}_1] & Cov[\hat{\beta}_1, \hat{\beta}_2] & \cdots & Cov[\hat{\beta}_1, \hat{\beta}_K] \\ Cov[\hat{\beta}_1, \hat{\beta}_2] & V[\hat{\beta}_2] & \cdots & Cov[\hat{\beta}_2, \hat{\beta}_K] \\ \vdots & \vdots & \ddots & \vdots \\ Cov[\hat{\beta}_1, \hat{\beta}_K] & Cov[\hat{\beta}_2, \hat{\beta}_K] & \cdots & V[\hat{\beta}_K] \end{bmatrix}$$
$$= \begin{bmatrix} \sigma^2 A_{11} & \sigma^2 A_{12} & \cdots & \sigma^2 A_{1K} \\ \sigma^2 A_{21} & \sigma^2 A_{22} & \cdots & \sigma^2 A_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^2 A_{K1} & \sigma^2 A_{K2} & \cdots & \sigma^2 A_{KK} \end{bmatrix}$$

donde  $A_{kk}$  es el elemento en la fila  $k$  y columna  $k$  de la matriz  $(X'X)^{-1}$

- El estimador de  $VarCov(\hat{\beta})$  es  $Var\hat{Cov}(\hat{\beta}) = S^2(X'X)^{-1}$   
con  $S^2 = \frac{e'e}{n-K}$

# Supuestos

## Definición: matriz semidefinida positiva

Sea  $H$  una matriz  $m \times m$  y sea  $c$  cualquier vector de  $m$  constantes. Se dice que  $H$  es semidefinida positiva si y sólo si  $c'Hc \geq 0 \forall c \in \mathbb{R}^m$

- Notar:
  - que  $c'Hc$  es  $(1 \times 1)$ , o sea, un número real.
  - $c'Hc$  es una **forma cuadrática**. Para ver por qué, desarrollar la expresión para  $m = 2$ .
- **Importante:** cualquier matriz de varianzas y covarianzas es semidefinida positiva.
  - En particular,  $VarCov[\hat{\beta}]$  es semidefinida positiva.

# Supuestos

- Entonces, para cualquier vector de constantes  $c$  de dimensión  $K \times 1$  se cumple que  $c' \text{VarCov}[\hat{\beta}]c \geq 0$ .
- La expresión  $c' \text{VarCov}[\hat{\beta}]c$  es la varianza de la combinación lineal  $c' \hat{\beta}$ .
- Veamos el ejemplo para  $K = 2$ :
  - $c' \hat{\beta} = c_1 \hat{\beta}_1 + c_2 \hat{\beta}_2$
  - $V[c' \hat{\beta}] = c' \text{VarCov}[\hat{\beta}]c = c_1^2 V[\hat{\beta}_1] + c_2^2 V[\hat{\beta}_2] + 2c_1 c_2 \text{Cov}[\hat{\beta}_1, \hat{\beta}_2]$
  - La semidefinición positiva garantiza que esta última expresión es  $\geq 0$ .
- Entonces todos los siguientes casos particulares son  $\geq 0$ :
  - Si  $c_1 = 1$  y  $c_2 = 0 \Rightarrow V[c' \hat{\beta}] = V[\hat{\beta}_1] \geq 0$
  - Si  $c_1 = 0$  y  $c_2 = 1 \Rightarrow V[c' \hat{\beta}] = V[\hat{\beta}_2] \geq 0$
  - Si  $c_1 = 1$  y  $c_2 = 1 \Rightarrow V[c' \hat{\beta}] = V[\hat{\beta}_1] + V[\hat{\beta}_2] + 2\text{Cov}[\hat{\beta}_1, \hat{\beta}_2] \geq 0$
  - Si  $c_1 = 1$  y  $c_2 = -1 \Rightarrow V[c' \hat{\beta}] = V[\hat{\beta}_1] + V[\hat{\beta}_2] - 2\text{Cov}[\hat{\beta}_1, \hat{\beta}_2] \geq 0$



# Teorema de Gauss Markov

---

- Bajo todos los supuestos clásicos, el estimador de MCO es el más eficiente de todos los estimadores lineales e insesgados.
- **Mejor Estimador Lineal e Insesgado (MELI).**
- **Además:** sea  $c$  un vector de  $K$  constantes arbitrarias  $c_1, c_2, \dots, c_K$ ,  $c'\hat{\beta}$  es el mejor estimador lineal e insesgado de  $c'\beta$ .
  - Es decir, la combinación lineal de los estimadores MCO es MELI para estimar la combinación lineal de los parámetros.